


Segurança de prompts em modelos de LLMS

Primeira Versão Completa - artigo

Juan Gustavo, Lucas Emanuel, Lucas Messias, Joás Vitor e João Victor



Introdução

Contextualiza a importância dos LLMs e seus riscos, como prompt injection, jailbreak, vieses e PII.

Apresenta limitações das soluções existentes e justifica a necessidade de uma arquitetura multicamadas.

Resume as contribuições do trabalho e a estrutura do artigo.

1. Introdução

Modelos de Linguagem de Grande Escala (LLMs) têm se tornado componentes centrais em aplicações modernas, incluindo assistentes virtuais, sistemas conversacionais, plataformas educacionais e ambientes corporativos. Sua capacidade de gerar, interpretar e transformar linguagem natural em larga escala permite níveis de automação antes inviáveis. Entretanto, essa mesma flexibilidade introduz riscos significativos relacionados à segurança, ética e confiabilidade, especialmente quando tais modelos são expostos diretamente a usuários finais ou integrados a sistemas críticos.

Diversas vulnerabilidades inerentes aos LLMs têm sido amplamente documentadas na literatura, incluindo ataques de *prompt injection*, tentativas de *jailbreak* para subverter instruções do sistema, geração de conteúdo malicioso, vieses socioculturais reproduzidos ou amplificados pelo modelo e alucinações (*hallucinations*) que podem resultar em informações factualmente incorretas ou perigosas. Além disso, LLMs podem inadvertidamente vaziar informações pessoais identificáveis (PII), expondo organizações e usuários a riscos legais e de privacidade.

Soluções tradicionais baseadas apenas em filtragem estática, listas de bloqueio ou simples verificações sintáticas têm se mostrado insuficientes para lidar com ameaças cada vez mais sofisticadas. Isso ocorre porque muitos ataques exploram dependências semânticas, ambiguidades linguísticas e lacunas nos mecanismos de alinhamento do modelo, exigindo abordagens mais abrangentes e sensíveis ao contexto.

Diante desse cenário, este trabalho propõe uma arquitetura multicamadas para segurança de LLMs, composta por módulos de sanitização estrutural, detecção de

Trabalhos Relacionados

Comparação entre cinco estudos sobre segurança em LLMs.

Análise de metodologias, métricas e lacunas de cada trabalho.

TABLE I COMPARISON OF RELATED WORKS ON PROMPT INJECTION DEFENSE IN LLMs				
Referencia	Foco	Metodologia	Métricas	Lacuna
Lin, Huawei <i>et al.</i> [1]	Proposta de defesa unificada (UniGuardian) contra ataques de LLM (injeção, backdoor, adversariais).	Propõe um framework de detecção unificado para analisar prompts e saídas.	(1) auROC (Area Under the Receiver Operator Characteristic Curve) e (2) auPRC (Area Under the Precision-Recall Curve).	Falta de profundidade no que tange a ataques de backdoor mais complexos ou ofuscados, gerando falsos positivos.
Hong, Hanbin <i>et al.</i> [2]	Sistematização do conhecimento em segurança de prompts em LLMs, propondo uma taxonomia e um conjunto de métricas próprias para padronizar avaliações de ataques e defesas.	Revisão sistemática e proposta de uma taxonomia multi-nível. Desenvolvimento de toolkit aberto e dataset (JailbreakDB) para avaliação padronizada.	Propõe métricas padronizadas próprias integradas a um toolkit de avaliação com taxonomia hierárquica e perfis de ameaça formais.	Limitação na aplicação prática das métricas e taxonomias propostas; necessidade de validação contínua e ampliação para modelos multimodais e cenários reais.
Chen, Sizhe <i>et al.</i> [3]	Proposta de defesa chamada <i>StruQ</i> , que utiliza consultas estruturadas (<i>structured queries</i>) para separar dados do prompt, reduzindo o risco de injeções maliciosas em LLMs.	Implementação experimental com análise de desempenho e eficácia em diferentes cenários de injeção. Avalia a separação entre dados e instruções para mitigar ataques.	Taxa de sucesso de ataque, latência e sobrecarga do sistema (<i>defense overhead</i>).	Boa eficácia em prompts simples, mas limitação em ataques indiretos e cenários complexos de múltiplas etapas, exigindo integração com outras técnicas de defesa.
Benjamin, Victoria <i>et al.</i> [4]	Análise sistemática da vulnerabilidade de 36 LLMs a ataques de injeção de prompt focados em gerar código de keylogger.	4 prompts de injeção direta contra 36 LLMs. Análise estatística (Correlação, Random Forest, SHAP, PCA).	(1) Taxa de sucesso (2) Importância de features. (3) Correlação entre prompts.	Necessidade de testes multilíngues, múltiplas etapas de complexidade.
Sebastian, Glorin. [5]	Investigar a proteção de dados e privacidade em chatbots (foco no ChatGPT). Avaliar Tecnologias de Aprimoramento de Privacidade (PETs).	Revisão da literatura, análise de técnicas (ex: privacidade diferencial) e uma pesquisa (survey) com 177 usuários.	Métricas de percepção da pesquisa: (1) Nível de preocupação, (2) Disposição para sacrificar desempenho, (3) Consciência sobre vazamentos.	Análise de riscos à privacidade, preocupação dos usuários através de pesquisas.
This Work	Análise comparativa de frameworks de defesa contra injeção de prompt em LLMs.	Prova de conceito e simulações baseadas em diferentes cenários de ataque.	Taxa de sucesso de ataque, resiliência e custo computacional.	Busca preencher a lacuna de falta de metodologia padronizada para comparação empírica entre defesas.

Metodologia

Levantamento do estado da arte

Busca em base de artigos

Desenvolvimento da Prova de Conceito (POC)

Construção da ferramenta de segurança

Casos de Teste

Precisão, Recall, Acurácia, F1 e tempo.

Sistematização dos Resultados e elaboração do Artigo

Descrição detalhada do fluxo de execução e resultados

3. Metodologia

A metodologia adotada neste trabalho foi estruturada de forma a avaliar, de maneira sistemática e controlada, a eficácia da arquitetura proposta para segurança em Modelos de Linguagem de Grande Escala (LLMs). O processo metodológico integra a geração de cenários de ataque, a classificação de riscos, a execução de testes em múltiplos idiomas e a análise quantitativa dos resultados, permitindo uma investigação abrangente das capacidades e limitações do sistema.

3.1. Levantamento do estado da arte

Para fundamentar a investigação proposta, realizou-se um levantamento sistemático do referencial teórico em bases de dados amplamente reconhecidas na área de Computação e Inteligência Artificial, incluindo Google Acadêmico, IEEE Xplore e a Plataforma Lattes. A busca foi conduzida utilizando um conjunto de palavras-chave relacionadas ao tema central deste estudo, tais como “segurança de prompts”, “prompt injection”, “LLM security” e “prompt-based attacks”.

Inicialmente, os resultados recuperados foram triados com base nos títulos e resumos, de modo a identificar pesquisas diretamente alinhadas à temática de segurança em Modelos de Linguagem de Grande Escala (LLMs). Em seguida, procedeu-se à análise exploratória dos textos selecionados, considerando critérios como relevância metodológica, atualidade das abordagens e potencial contribuição para a compreensão do estado da arte.

Após esse processo de filtragem, cinco estudos foram selecionados para análise detalhada no âmbito deste projeto. Esses trabalhos representam diferentes perspectivas e metodologias aplicadas à mitigação de ataques de injeção de prompt e à avaliação de mecanismos de segurança em LLMs, fornecendo uma base sólida para a discussão crítica e para o desenvolvimento da abordagem proposta.

3.2. Desenvolvimento da Prova de Conceito (POC)

Após a elaboração do referencial teórico e a identificação das abordagens mais relevantes na área de segurança de prompts, procedeu-se ao desenvolvimento de um conjunto de aplicações destinadas à validação prática das técnicas analisadas. Esse desenvolvimento ocorreu de forma incremental, permitindo a implementação, teste e aprimoramento progressivo das funcionalidades relacionadas à detecção e mitigação de injeções de prompt em Modelos de Linguagem de Grande Escala (LLMs).

O ambiente experimental foi estruturado utilizando Python como linguagem base, devido à sua ampla adoção em projetos de inteligência artificial e ao ecossistema robusto de bibliotecas voltadas para processamento linguístico. Para a construção dos serviços de backend e exposição

Conclusão e Trabalhos Futuros

1

Síntese da Eficácia

Arquitetura eficaz para ataques explícitos e PII.

2

Limitações

Dificuldade na detecção de vieses.

5. Conclusão e Trabalhos Futuros

Este trabalho apresentou uma arquitetura multicamadas voltada para a segurança de Modelos de Linguagem de Grande Escala (LLMs), integrando mecanismos de sanitização, detecção de riscos explícitos, identificação de vieses e validação pós-geração. Os experimentos realizados demonstraram que a abordagem é tecnicamente viável, resiliente e capaz de mitigar de forma eficaz uma variedade de ameaças associadas ao uso de LLMs em ambientes abertos.

O sistema mostrou desempenho robusto na detecção de ataques explícitos, incluindo tentativas de *prompt injection*, *jailbreak* e solicitações maliciosas, além de apresentar eficácia total em todas as categorias de informações pessoais identificáveis (PII). As métricas obtidas — com F1-score igual a 1.00 para categorias de risco explícito — validam a capacidade da arquitetura de atuar como um mecanismo confiável de defesa em camadas. A ausência de falsos positivos reforça a minimização de interferência indevida na experiência do usuário.

Por outro lado, os resultados também evidenciaram limitações importantes, sobretudo na detecção de vieses linguísticos implícitos. Categorias como gênero, corpo, educação e LGBTQIA+ permaneceram com baixa ou nula taxa de sucesso, indicando que heurísticas baseadas apenas em regras e padrões simples não são suficientes para capturar nuances semânticas presentes em conteúdos enviesados. Essa limitação é consistente com desafios identificados na literatura e reforça a necessidade de incorporar mecanismos mais avançados de análise.

De forma geral, os resultados confirmam a hipótese central deste trabalho: *uma arquitetura multicamadas, sensível ao contexto e baseada em verificações estruturais e semânticas, aumenta significativamente a segurança e a confiabilidade de sistemas baseados em LLMs*. O modelo proposto estabelece um arcabouço sólido para futuras extensões e aprimoramentos em sistemas de IA responsáveis.