


Resultados da análise de plágio:

ferramenta: <https://www.duplichecker.com/>

Introdução



Trabalhos Relacionados

Plagiarism Checker

Check Grammar

AI Detector

Pro

Scan Properties

Sources Found0

Words532

Characters3834

View More Details

Plagiarism0%

0% Exact Match

0% Partial Match

Unique100%

Para a construção do referencial teórico deste trabalho, realizou-se uma análise sistemática de publicações recentes que investigam a segurança de prompts em Modelos de Linguagem de Grande Escala (LLMs). Os estudos examinados abrangem propostas de frameworks de defesa, sistematizações de conhecimento, mecanismos baseados em consultas estruturadas, análises empíricas de vulnerabilidades e avaliações voltadas à privacidade e percepção dos usuários. Essa revisão permitiu delinear o estado da arte, evidenciando o progresso alcançado na compreensão e mitigação de ataques de injeção de prompt e ameaças correlatas.

Entretanto, a análise comparativa revelou que cada um desses trabalhos apresenta limitações relevantes. Como pode ser observado na Tabela 1:

Lin, Huawei Proposta de defesa unificada (UniGuardian) contra ataques de LLM (injeção, backdoor, adversariais) Propõe um framework de detecção unificado para analisar prompts e saídas. (1) auROC (Area Under the Receiver Operator Characteristic Curve) e (2) auPRC (Area Under the Precision-Recall Curve). Falta de profundidade no que tange a ataques de backdoor mais complexos ou ofuscados, gerando falsos



Congratulations !
No Plagiarism Found

Metodologia

Plagiarism Checker

Check Grammar

AI Detector

Pro

Scan Properties

Sources Found0

Words643

Characters4708

View More Details

Plagiarism0%

0% Exact Match

0% Partial Match

Unique100%

A metodologia adotada neste trabalho foi estruturada de forma a avaliar, de maneira sistemática e controlada, a eficácia da arquitetura proposta para segurança em Modelos de Linguagem de Grande Escala (LLMs). O processo metodológico integra a geração de cenários de ataque, a classificação de riscos, a execução de testes em múltiplos idiomas e a análise quantitativa dos resultados, permitindo uma investigação abrangente das capacidades e limitações do sistema.

Levantamento do estado da arte

Para fundamentar a investigação proposta, realizou-se um levantamento sistemático do referencial teórico em bases de dados amplamente reconhecidas na área de Computação e Inteligência Artificial, incluindo Google Acadêmico, IEEE Xplore e a Plataforma Lattes. A busca foi conduzida utilizando um conjunto de palavras-chave relacionadas ao tema central deste estudo, tais como “segurança de prompts”, “prompt injection”, “LLM security” e “prompt-based attacks”.

Inicialmente, os resultados recuperados foram triados com base nos títulos e resumos, de modo a identificar pesquisas diretamente alinhadas à temática de segurança em Modelos de Linguagem de Grande Escala (LLMs). Em seguida, procedeu-se à análise exploratória



Congratulations !
No Plagiarism Found

Resultados

Plagiarism Checker

Check Grammar

AI Detector



Scan Properties

Sources Found0

Words787

Characters6236

View More Details

Plagiarism0%


0% Exact Match

0% Partial Match

Unique100%

Esta seção apresenta a ferramenta desenvolvida para tratar a segurança de prompts em contextos de LLMs, bem como a análise detalhada dos experimentos conduzidos para avaliar a eficácia da arquitetura proposta. Foram analisadas métricas de desempenho, taxas de sucesso, matriz de confusão e tempos de resposta, utilizando 30 casos de teste distribuídos entre categorias críticas, como vieses, ataques maliciosos, tentativas de \textit{jailbreak} e detecção de PII. Os resultados permitem identificar pontos fortes e limitações da solução, fornecendo evidências quantitativas para validação da hipótese central deste trabalho.

A arquitetura proposta foi concebida como um sistema multicamadas de segurança para Modelos de Linguagem de Grande Escala (LLMs), com o objetivo de detectar, mitigar e bloquear ameaças semânticas e estruturais ao longo de todo o ciclo de processamento dos prompts. A necessidade de múltiplas camadas decorre da diversidade de riscos enfrentados, incluindo injeções de prompt, alucinações do modelo, vieses linguísticos e vazamento de informações sensíveis. A abordagem modular permite distribuir responsabilidades entre componentes especializados, garantindo robustez, escalabilidade e auditabilidade. A Figura~\ref{fig:architecture} apresenta uma visão aeral da arquitetura



Congratulations !
No Plagiarism Found

Conclusão e Trabalhos Futuros

Plagiarism Checker

Check Grammar

AI Detector



Scan Properties

Sources Found0

Words323

Characters2347

View More Details

Plagiarism0%

0% Exact Match


0% Partial Match

Unique100%

Este trabalho apresentou uma arquitetura multicamadas voltada para a segurança de Modelos de Linguagem de Grande Escala (LLMs), integrando mecanismos de sanitização, detecção de riscos explícitos, identificação de vieses e validação pós-geração. Os experimentos realizados demonstraram que a abordagem é tecnicamente viável, resiliente e capaz de mitigar de forma eficaz uma variedade de ameaças associadas ao uso de LLMs em ambientes abertos.

O sistema mostrou desempenho robusto na detecção de ataques explícitos, incluindo tentativas de \textit{prompt injection}, \textit{jailbreak} e solicitações maliciosas, além de apresentar eficácia total em todas as categorias de informações pessoais identificáveis (PII). As métricas obtidas — com F1-score igual a 1.00 para categorias de risco explícito — validam a capacidade da arquitetura de atuar como um mecanismo confiável de defesa em camadas. A ausência de falsos positivos reforça a minimização de interferência indevida na experiência do usuário.

Por outro lado, os resultados também evidenciaram limitações importantes, sobretudo na detecção de vieses linguísticos implícitos. Categorias como gênero, corpo e grau de educação permaneceram



Congratulations !
No Plagiarism Found